

Spécification technique complète

SEO + AEO + GEO pour un blog destiné à Google Search et aux assistants IA

Version : 1.0

Objet : Définir les exigences techniques, éditoriales, sémantiques et opérationnelles pour maximiser la visibilité d'un blog dans Google Search, Google AI Overviews / AI Mode, ChatGPT Search, Perplexity et les assistants génératifs qui s'appuient sur le web.

Principe directeur : il n'existe pas, côté Google, d'optimisation séparée qui remplacerait le SEO pour les expériences génératives ; Google indique que ces fonctionnalités reposent sur ses systèmes de recherche et de qualité existants, donc les fondamentaux SEO restent la base.

1. Objet du document

Ce document décrit la cible minimale à atteindre pour qu'un blog soit :

- facilement crawlé et indexé ;
- techniquement propre ;
- compris comme une entité fiable ;
- lisible par les systèmes de recherche classiques et génératifs ;
- structuré de manière à favoriser l'extraction de réponses, de citations, de snippets et de résumés automatiques.

Il ne s'agit pas d'une liste d'astuces isolées, mais d'un cadre de production. Le but est de réduire au maximum les frictions techniques et les ambiguïtés sémantiques. Google rappelle que le SEO consiste à aider les moteurs à comprendre le contenu et les utilisateurs à trouver ce contenu ; ses recommandations officielles pour les expériences génératives réaffirment que les bonnes pratiques SEO continuent de s'appliquer.

2. Résultat attendu

Le blog doit atteindre simultanément les objectifs suivants :

1. apparaître dans les résultats organiques classiques ;
2. être éligible aux extraits enrichis et aux snippets utiles ;
3. être compréhensible par les systèmes de recherche générative ;
4. produire des signaux d'autorité cohérents ;
5. permettre une indexation stable et prévisible ;
6. conserver une bonne performance mobile et une bonne expérience utilisateur.

Google précise que les systèmes d'IA dans Search s'appuient sur ses systèmes de ranking et de qualité, et que le contenu utile, fiable et people-first demeure central.

3. Principes non négociables

3.1. Le contenu doit rester visible, utile et vérifiable

Tout balisage, toute donnée structurée et toute optimisation doit correspondre à du contenu réellement visible dans la page. Google recommande explicitement que les données structurées reflètent le contenu visible et soient validées avant mise en production.

3.2. Le blog doit être une entité, pas seulement une collection d'articles

Le site doit exprimer une identité stable :

- nom du site ;
- auteur ou auteurs ;
- organisation responsable ;
- page À propos ;
- pages de contact ou de profil ;
- profils externes cohérents via `sameAs` .

Google indique que le site name est distinct du title link de chaque page, et que les données structurées `Organization` et `Person` aident à identifier l'entité derrière le contenu.

3.3. Le système doit être simple à crawler

Google rappelle que `robots.txt` sert à gérer l'accès des crawlers aux URLs, mais pas à masquer une page des résultats ; pour empêcher l'indexation, il faut utiliser `noindex` ou protéger la page.

4. Architecture cible du site

4.1. Arborescence recommandée

Le site doit être organisé en couches :

- page d'accueil ;
- pages piliers par grande thématique ;
- articles de profondeur ;
- pages auteur ;
- page À propos ;
- pages catégories si elles ont une vraie valeur éditoriale ;
- pages techniques : politique de confidentialité, contact, mentions légales ;
- éventuellement base documentaire, glossaire, FAQ réelle si nécessaire.

4.2. Modèle d'entité

Le site doit distinguer clairement :

- `Organization` : l'entité éditoriale ou la marque ;
- `Person` : l'auteur ou les auteurs ;
- `WebSite` : le site dans son ensemble ;

- `WebPage` : chaque page individuelle ;
- `Article` ou `BlogPosting` : chaque article ;
- `BreadcrumbList` : la hiérarchie de navigation.

Google documente explicitement l'usage de structured data pour aider à comprendre le contenu, les entités et les relations entre pages.

5. Exigences techniques de base

5.1. Protocole, domaine et redirections

- HTTPS obligatoire.
- Une seule version canonique du domaine.
- Redirections 301 propres de toutes les variantes non canoniques.
- Aucune duplication entre `www` et non-`www`.
- Aucune duplication entre HTTP et HTTPS.
- Aucune duplication entre slash final et non-slash final si la convention choisie est stable.

5.2. Canonicalisation

Chaque page indexable doit contenir une balise canonical absolue vers elle-même ou vers sa version canonique réelle.

```
<link rel="canonical" href="https://example.com/mon-article" />
```

Aucune canonical ne doit pointer vers une page en redirection, une page de pagination incorrecte ou une variante incohérente.

5.3. Sitemaps

Mettre en place :

- `sitemap.xml` ;
- `sitemap-index.xml` si le volume l'exige ;
- `sitemap-images.xml` si les images sont stratégiques ;
- éventuellement `sitemap-news.xml` si le site publie de l'actualité et respecte les conditions du format.

Les sitemaps doivent être auto-générés, à jour, et déclarés dans `robots.txt`. Google recommande les sitemaps comme aide au crawl et à la découverte.

5.4. Performance

Le site doit être performant sur mobile, car Google continue de s'appuyer sur l'expérience de page et sur les Core Web Vitals. L'objectif est d'obtenir un chargement rapide, une interaction fluide et une stabilité visuelle correcte.

Exigences minimales :

- LCP optimisé ;
- INP bas ;
- CLS faible ;
- images compressées ;
- chargement différé des ressources non critiques ;
- code JS réduit au strict nécessaire.

5.5. Rendu et crawl

Le contenu essentiel ne doit pas dépendre exclusivement d'un JavaScript tardif ou fragile. Le texte principal, les titres, les liens, les métadonnées et le contenu de fond doivent être disponibles pour le crawler avec un minimum de friction. Cela n'est pas une exigence "IA" spéciale : c'est une exigence générale de crawl et d'indexation.

6. Exigences HTML par page

6.1. Title

Chaque page doit avoir un titre unique, descriptif et court. Google indique qu'il utilise plusieurs sources pour générer le titre link et qu'il est possible d'influencer ce titre par de bonnes pratiques de rédaction et de structure.

Règles :

- un titre unique par page ;
- pas de bourrage de mots-clés ;
- pas de répétition mécanique du nom du site ;
- priorité au sujet réel de la page.

6.2. Meta description

Chaque page doit avoir une meta description unique, courte, informative et rédigée pour l'utilisateur. Elle n'est pas un facteur de classement direct, mais elle influence souvent l'extrait affiché.

6.3. H1 et hiérarchie

- un seul H1 par page ;
- des H2 qui structurent les grandes sections ;
- des H3 pour les sous-sections ;
- pas de saut de hiérarchie inutile ;
- des titres qui décrivent réellement le contenu.

6.4. Images

Chaque image significative doit avoir :

- un `alt` descriptif ;
- un nom de fichier propre ;

- une largeur et une hauteur définies ;
- une version optimisée ;
- un contexte proche du texte auquel elle se rapporte.

Google recommande d'utiliser les images et métadonnées d'image pour aider à la compréhension du contenu, et d'écrire des alt qui décrivent réellement l'image.

7. Structured data obligatoire

Google explique que les données structurées aident ses systèmes à comprendre le contenu de la page et peuvent rendre le contenu éligible à des affichages plus riches. Elles ne garantissent pas un rich result, mais elles augmentent la lisibilité machine.

7.1. Format exigé

- JSON-LD uniquement.
- Pas de microdata sauf contrainte exceptionnelle.
- Toutes les propriétés déclarées doivent correspondre à du contenu visible.

7.2. Home page

La home doit inclure :

- `WebSite`
- `Organization`
- `WebPage`

La home doit contenir :

- le nom du site ;
- une présentation claire ;
- un lien vers la page À propos ;
- des références à l'entité responsable.

Google distingue explicitement le site name du title link et recommande d'utiliser un nom de site cohérent.

7.3. Articles

Chaque article doit inclure `Article` ou `BlogPosting` avec :

- `headline`
- `image`
- `author`
- `publisher`
- `datePublished`
- `dateModified`
- `mainEntityOfPage`

Google recommande `datePublished` et `dateModified` pour une datation plus précise, et rappelle que `headline`, `image`, `author` et les dates sont des éléments importants du balisage Article.

7.4. Auteur

L'auteur doit être balisé en `Person` avec :

- `name`
- `url`
- `image`
- `sameAs`
- `worksFor` si pertinent et vrai

Le profil auteur doit exister comme page dédiée ou comme section clairement identifiable. Google a ajouté des recommandations spécifiques sur le balisage auteur pour Article.

7.5. Organisation

L'organisation doit inclure :

- nom ;
- logo ;
- URL ;
- `sameAs` vers des profils ou pages officielles pertinentes ;
- coordonnées si elles sont publiques et exactes.

Google documente `sameAs` pour `Organization` comme un moyen d'associer l'entité à des pages externes utiles.

7.6. BreadcrumbList

Toutes les pages internes importantes doivent avoir un fil d'Ariane balisé. Cela aide la compréhension de l'arborescence et la présentation dans les résultats.

8. Politique de contenu

8.1. Exigence centrale

Chaque article doit répondre directement à la question principale dans les premiers paragraphes. Google insiste sur le contenu utile, fiable et people-first, et sur la nécessité de produire une information originale et satisfaisante.

8.2. Structure éditoriale d'un article

Chaque article doit contenir :

- une réponse courte au début ;
- un résumé extractible ;
- des sections claires ;

- des sous-titres informatifs ;
- des exemples concrets ;
- des tableaux si la comparaison l'exige ;
- une conclusion utile ;
- des sources ou références lorsque la matière le justifie.

8.3. Signaux de qualité

Le contenu doit privilégier :

- l'expérience réelle ;
- la méthode ;
- les données originales ;
- les tests ;
- les limites ;
- les nuances.

Google dit explicitement qu'il faut créer du contenu utile, fiable et people-first, et que les systèmes de recherche et d'IA récompensent le contenu réellement utile.

8.4. AI-generated content

L'usage d'IA pour produire du contenu n'est pas interdit par Google ; ce qui est interdit, c'est l'usage de l'automatisation pour manipuler les classements ou produire du contenu trompeur à grande échelle.

9. Autorité d'entité et E-E-A-T

9.1. Ce que le site doit démontrer

Le site doit rendre visibles :

- qui écrit ;
- pourquoi cette personne est crédible ;
- de quelle organisation elle dépend ;
- comment les affirmations ont été vérifiées ;
- quelles sources sont utilisées ;
- comment les données sont obtenues.

9.2. Pages obligatoires

- page À propos ;
- page auteur ;
- page contact ;
- politique éditoriale ;
- éventuellement page méthodologie.

9.3. Cohérence absolue

Le nom de l'auteur, la bio, l'image, le site name, les profils externes et les mentions légales doivent être cohérents partout. Plus la cohérence d'entité est forte, plus il est facile pour les systèmes de relier le contenu à une source crédible.

10. SEO de site

10.1. Maillage interne

Le blog doit être structuré en :

- pages piliers ;
- articles satellites ;
- liens contextuels ;
- liens de retour vers les pages piliers ;
- sections "articles liés" pertinentes.

10.2. Navigation

- menu clair ;
- catégories non surchargées ;
- fil d'Ariane ;
- footer utile ;
- page À propos accessible depuis la home.

10.3. Pagination et archives

Les archives doivent être gérées proprement pour éviter les doublons et les pages sans valeur. Les pages de liste doivent être utiles, navigables et indexables seulement si elles apportent une vraie valeur.

11. Spécifications robots.txt

Google rappelle que `robots.txt` gère le crawl, pas l'indexation, et qu'il faut utiliser `noindex` ou protéger la page pour empêcher l'indexation.

11.1. Principes

Le fichier `robots.txt` doit :

- autoriser le crawl du contenu public ;
- empêcher les zones techniques ou privées d'être crawled ;
- déclarer le sitemap ;
- séparer le crawl de recherche et l'entraînement si le projet le souhaite.

11.2. OpenAI

OpenAI documente deux agents distincts :

- `OAI-SearchBot` pour la recherche dans ChatGPT Search ;
- `GPTBot` pour l'entraînement des modèles.

OpenAI indique qu'un site peut autoriser `OAI-SearchBot` pour apparaître dans les résultats de recherche tout en bloquant `GPTBot` pour empêcher l'usage à des fins d'entraînement.

11.3. Perplexity

Perplexity documente également deux usages :

- `PerplexityBot` pour faire apparaître et lier des sites dans les résultats ;
- `Perplexity-User` pour les actions initiées par l'utilisateur.

Perplexity précise que `Perplexity-User` n'est pas utilisé pour le crawl web ni pour l'entraînement de modèles de fondation.

11.4. Google

Google distingue ses règles de crawl Search de `Google-Extended`, qui sert à gérer l'usage du contenu crawlé pour certains usages liés à l'IA de Google. Google précise aussi que les AI features de Search reposent sur les systèmes de recherche existants.

11.5. Politique recommandée

Politique minimale recommandée :

```
User-agent: Googlebot
Allow: /

User-agent: OAI-SearchBot
Allow: /

User-agent: GPTBot
Disallow: /

User-agent: PerplexityBot
Allow: /

User-agent: Perplexity-User
Allow: /

User-agent: Google-Extended
Allow: /

Sitemap: https://example.com/sitemap.xml
```

Cette politique doit être adaptée aux objectifs du projet. Si le site ne souhaite pas participer à l'entraînement, il peut bloquer les robots d'entraînement tout en gardant les robots de recherche ouverts. C'est cohérent avec la séparation documentée par OpenAI et Perplexity.

11.6. Anthropic

Les règles spécifiques d'accès pour Anthropic doivent être vérifiées dans la documentation officielle la plus récente avant d'être codées en dur dans `robots.txt`. Le principe à retenir est simple : ne jamais figer un nom d'agent sans vérifier sa documentation actuelle.

12. llms.txt

Le fichier `/llms.txt` est une proposition communautaire destinée à fournir un résumé lisible par des LLMs au moment de l'inférence ; ce n'est pas une exigence de Google Search. Le projet `llms.txt` le présente explicitement comme une proposition de standardisation, tandis que Google indique que les fichiers de ce type ne changent rien à son Search.

12.1. Rôle

`llms.txt` peut servir à :

- documenter les pages clés ;
- orienter un assistant qui consulte le site ;
- fournir un sommaire humainement lisible ;
- résumer la structure du site.

12.2. Statut

- utile comme couche documentaire ;
 - non déterminant pour Google Search ;
 - à maintenir si le site cible des assistants qui l'exploitent volontairement ;
 - à considérer comme complément, pas comme fondation.
-

13. Métadonnées sociales

Toutes les pages importantes doivent avoir :

- Open Graph ;
- Twitter Card ;
- image de partage cohérente ;
- title et description adaptés au partage.

Les pages partagées doivent rester lisibles, résumables et visuellement cohérentes sur les plateformes sociales.

14. Accessibilité

Le site doit être accessible :

- structure HTML valide ;
- navigation clavier ;
- focus visible ;
- labels explicites ;
- contraste suffisant ;
- textes alternatifs ;
- boutons et liens accessibles.

L'accessibilité améliore la lisibilité pour tous les utilisateurs et réduit les ambiguïtés pour les systèmes automatiques.

15. Sécurité et headers HTTP

Mettre en place les headers adaptés :

- Content-Security-Policy
- Strict-Transport-Security
- X-Frame-Options ou équivalent moderne si nécessaire
- Referrer-Policy
- Permissions-Policy

Le site doit aussi éviter les erreurs courantes : ressources mixtes, chargements tiers excessifs, injections non maîtrisées, dépendances inutiles.

16. Analytics, Search Console et monitoring

Installer et surveiller :

- Google Search Console ;
- Google Analytics ou solution équivalente ;
- Bing Webmaster Tools si pertinent ;
- monitoring d'erreurs 404 ;
- rapport de couverture / indexation ;
- Core Web Vitals ;
- sitemap ;
- performances par page pilier ;
- évolution des titres et snippets.

Google encourage l'usage de Search Console pour valider et surveiller les données structurées et l'indexation.

17. Processus de publication

Aucune page ne doit être publiée sans validation préalable :

- contenu terminé ;
- titre unique ;
- meta description unique ;
- H1 unique ;
- canonical correcte ;
- JSON-LD valide ;
- images optimisées ;
- alt présents ;
- liens internes vérifiés ;
- indexation souhaitée confirmée ;
- datePublished et dateModified cohérentes ;
- relecture éditoriale ;
- test mobile ;
- test de rendu ;
- validation Search Console si nécessaire.

Google recommande de tester les pages structurées avec ses outils, de s'assurer qu'elles sont accessibles au crawl et de laisser le temps au recrawl après publication.

18. Modèle de page type

18.1. Page d'article

La page d'article doit suivre ce modèle :

1. titre clair ;
2. résumé immédiat ;
3. réponse directe ;
4. développement en sections ;
5. preuve, méthode, exemples ;
6. conclusion utile ;
7. sources ;
8. auteur ;
9. date de mise à jour ;
10. liens vers les articles connexes.

18.2. Page À propos

La page À propos doit contenir :

- identité du site ;
- mission ;
- responsable ;
- méthode éditoriale ;
- liens externes officiels ;
- photo ou logo ;

- preuve d'existence de l'entité.

18.3. Page auteur

La page auteur doit contenir :

- nom ;
 - rôle ;
 - expertise ;
 - bio courte ;
 - bio longue ;
 - photo ;
 - liens externes cohérents ;
 - historique des articles ;
 - éventuels domaines d'expertise.
-

19. Exemples de JSON-LD

19.1. Organization

```
{
  "@context": "https://schema.org",
  "@type": "Organization",
  "@id": "https://example.com/#organization",
  "name": "Nom du site",
  "url": "https://example.com/",
  "logo": {
    "@type": "ImageObject",
    "url": "https://example.com/logo.png"
  },
  "sameAs": [
    "https://github.com/...",
    "https://www.linkedin.com/company/..."
  ]
}
```

19.2. WebSite

```
{
  "@context": "https://schema.org",
  "@type": "WebSite",
  "@id": "https://example.com/#website",
  "url": "https://example.com/",
  "name": "Nom du site",
  "publisher": {
    "@id": "https://example.com/#organization"
  }
}
```

```
}  
}
```

19.3. Person

```
{  
  "@context": "https://schema.org",  
  "@type": "Person",  
  "@id": "https://example.com/auteur/#person",  
  "name": "Prénom Nom",  
  "url": "https://example.com/auteur/",  
  "image": "https://example.com/auteur.jpg",  
  "sameAs": [  
    "https://www.linkedin.com/in/...",  
    "https://github.com/..."  
  ],  
  "worksFor": {  
    "@id": "https://example.com/#organization"  
  }  
}
```

19.4. Article

```
{  
  "@context": "https://schema.org",  
  "@type": "Article",  
  "@id": "https://example.com/article/#article",  
  "headline": "Titre de l'article",  
  "image": [  
    "https://example.com/images/article-cover.jpg"  
  ],  
  "datePublished": "2026-07-20T08:00:00+01:00",  
  "dateModified": "2026-07-20T10:30:00+01:00",  
  "author": {  
    "@id": "https://example.com/auteur/#person"  
  },  
  "publisher": {  
    "@id": "https://example.com/#organization"  
  },  
  "mainEntityOfPage": {  
    "@id": "https://example.com/article/"  
  }  
}
```

19.5. BreadcrumbList

```
{  
  "@context": "https://schema.org",
```

```

"@type": "BreadcrumbList",
"itemListElement": [
  {
    "@type": "ListItem",
    "position": 1,
    "name": "Accueil",
    "item": "https://example.com/"
  },
  {
    "@type": "ListItem",
    "position": 2,
    "name": "Catégorie",
    "item": "https://example.com/categorie/"
  },
  {
    "@type": "ListItem",
    "position": 3,
    "name": "Article",
    "item": "https://example.com/article/"
  }
]
}

```

Google précise que les données structurées doivent rester alignées sur le contenu visible et peuvent être testées avant publication.

20. Définition de Done

Une page ou un article n'est considéré comme prêt que si tout ce qui suit est vrai :

- contenu utile et réellement publié ;
- title et meta description uniques ;
- H1 unique ;
- structure H2/H3 claire ;
- canonical correcte ;
- JSON-LD valide ;
- page rapide sur mobile ;
- images optimisées ;
- maillage interne présent ;
- auteur identifié ;
- page À propos accessible ;
- dates cohérentes ;
- aucune duplication critique ;
- aucune erreur de rendu ;
- sitemap à jour ;
- robots.txt conforme ;
- indexation voulue explicitement définie ;
- page testée dans Search Console.

21. Ordre de mise en œuvre

Phase 1 — Fondations

- domaine, HTTPS, redirections ;
- architecture du site ;
- sitemap ;
- robots.txt ;
- pages légales ;
- home + À propos.

Phase 2 — Entité

- page auteur ;
- Organization / Person / WebSite ;
- sameAs ;
- cohérence des noms et visuels.

Phase 3 — Modèle d'article

- template article ;
- datePublished / dateModified ;
- Article schema ;
- metadata sociale ;
- breadcrumbs.

Phase 4 — Contenu et maillage

- pages piliers ;
- clusters ;
- liens internes ;
- tableaux ;
- comparaisons ;
- sources ;
- originalité.

Phase 5 — Mesure

- Search Console ;
- analytics ;
- monitoring des snippets ;
- corrections itératives ;
- tests de validation.

22. Conclusion opérationnelle

Le meilleur résultat ne vient pas d'une optimisation isolée pour "AEO" ou "GEO", mais d'un système complet : base technique propre, contenu réellement utile, entité crédible, maillage cohérent, structured data exact, crawl simple et performance solide. Google dit explicitement que ses

fonctionnalités génératives reposent sur le SEO de fond, que les systèmes doivent rester utiles et fiables, et que les artifices destinés à manipuler la visibilité n'apportent pas de bénéfice durable.

Le travail du développeur consiste donc à rendre le site parfaitement lisible pour les humains et pour les machines, sans dissocier les deux.